PlainTalk：语言风格约束与评测装置的有效性论证

摘要

大语言模型的输出常见一类失效：事实不错但读不通，表现为一句并置多个概念、结论埋在依据之后、术语不解释。本文研究如何用推理期上下文约束改善这一问题，并给出约束体系与评测装置的有效性论证。做法是把风格分解为语气与人际、组织与篇章、符号与格式、语言层次与语域、信息与熵、语用与交互六个变量层，每层配可定位触发标记、改法与例外，形成四层技能包；评测采用生成端、改写端、判分端三角色互不可见的对照协议，配合零依赖检查器的机械核对。

在此基础上，本文建立五个模型。测量模型把判分端视为带误差的仪器，由双向重复估计误差尺度约 4.2 分，推出通过线应取不低于基线加 10；硬门模型按失效成本不对称筛出四道一票否决门；删除规则模型把「删空话、留断言」形式化为两类错误成本不同的分类器，预测规则层的增量在区分能力；缺口决策模型按期望损失给出两态发问阈值；读取成本模型解释结论前置的权重分配。

四轮试点与两轮六场景执行轮检验模型。试点显示规则版在两个场景分差为正 15.8 与 26.8，三臂消融中规则层在删除侧零误删而禁令臂误删 2 处；首轮执行轮中规则臂 6 个场景通过 3 个，基线臂通过 1 个，规则臂胜场全部落在保真维度，失败集中在删除侧与组织层；首轮同时暴露器材缺陷：事实表字符串令牌在行内代码、表格与短语插入场景产生 5 处假阳性，占全部报缺的 5/6，修订后复测假阳性清零、真实丢失仍被捕获。第二轮在执行轮修订后重跑，采用真实对调的 AB/BA 双序判定：规则臂与基线臂都更多失败于新增的粒度条件与保真条件，规则臂暴露出压缩与膨胀两个方向的长度越界。再用一组控制变量测试检验长度规则的边际效果，发现长度优先的写法会诱导补白与编造，据此改为素材优先。结论是规则层的价值在区分能力而非抑制强度，器材的确定性以令牌原子性为条件，任务长度约束必须写进规则层。本文的结论限于同一模型家族与受控素材。

关键词：语言风格控制；可验收评测；判分噪声；分类器成本；技能包

一、引言

大语言模型的输出常见一类失效：事实不错但读不通。一句并置多个概念，结论埋在依据后面，术语不解释，读者读到段尾才知道讲了什么。在只能修改提示词与技能包的部署条件下，这类问题无法靠解码期干预解决，只能靠可执行的写作约束与可重复的验收。

现有开源方案集中在删除词汇层的 AI 痕迹。lieflat-less-ai-tone 用 629 篇、282.7 万字的人机对照语料测量词频并设收录门槛；speak-human-tw 给 38 条模式配成对用例与量化阈值。这些工作回答的是「哪些词像 AI 写的」，没有回答「信息怎么摆读者才读得懂」。信息组织、论证顺序、指代链与术语解释的约束基本无人做，本文占这一块。

本文做三件事。第一，把风格从形容词改成变量：分解为语气与人际、组织与篇章、符号与格式、语言层次与语域、信息与熵、语用与交互六层，每层配可定位的触发标记、改法与例外，写成四层技能包。第二，设计生成端、改写端、判分端互不可见的评测装置，用机械核对与盲评分离确定性与或然性两类判定。第三，建立五个形式化模型，把「有效性」变成可估计的量，并用四轮试点与两轮执行轮检验，其中包括用实测反哺设计的三次修订。

本文的结论有两条。规则层的价值在区分能力而不是抑制强度，它解决「不加、不丢、不编」，不解决任务规定的长度；器材的确定性以事实表令牌的原子性为条件，令牌设计不当会让机械门冤杀好文本。两条结论都来自实测，后一条来自装置自己暴露的缺陷。

二、问题分析

2.1 分析框架

四个问题共用一条主线：变量分解解决「调什么」，规则设计解决「怎么写」，装置解决「怎么测」，模型解决「怎么判断有效」。其中问题三是本文的重点，因为它决定前两个问题的答案是否可信。

清晰性不是一个可直接测量的量，只能通过代理指标间接估计。代理指标的效度取决于三件事：构念是否对准清晰性而非文风偏好，测量是否可重复，效应是否能从噪声中分离。这三点分别对应后续的效度、信度与灵敏度分析。

2.2 技术路线

技术路线如图 1。设计侧自六层变量分解出发，落成四层技能包；验证侧自事实素材卡出发，经三角色协议与判分表产出结论；实测数据只进项目文档与装置，规则修订经用户审核后推进版本。

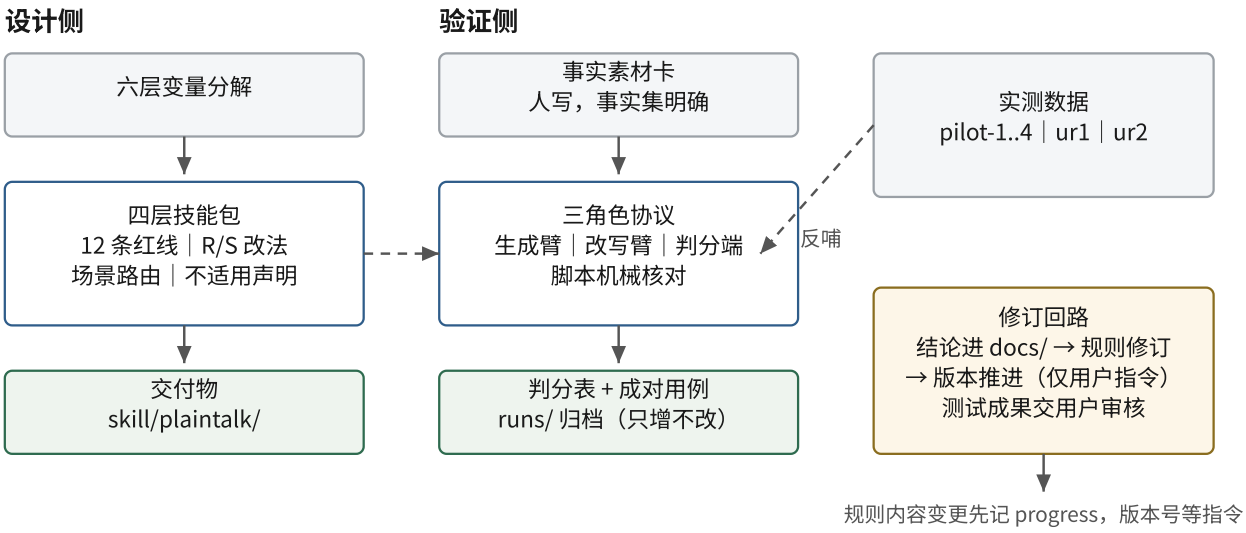


图 1 项目技术路线：变量分解、技能包、评测装置与修订回路的衔接关系

一轮测试的执行流程如图 2。生成端与改写端从同一素材各自生成，互不可见；匿名化后由脚本做机械核对，判分端在不知臂别的条件下双向重复判定，揭盲后计算分差。

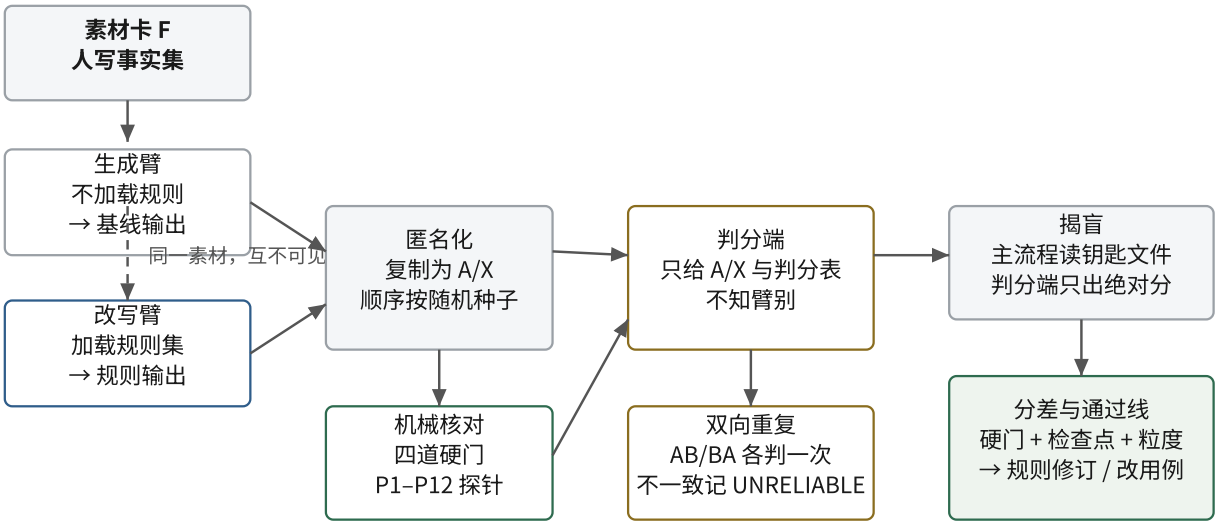


图 2 一轮测试的三角色流程与派工三禁

三、模型假设与符号说明

3.1 模型假设

假设 1：判分误差零均值、与文本质量独立。依据是 pilot-2 双向重复中同一文本两次判定的平均漂移为 4.25 分，正负方向各半，未呈现系统偏向。

假设 2：素材卡覆盖任务的必要事实。依据是六张素材卡的事实表由人工逐项核对，执行轮中真实丢失仅 1 例，说明覆盖基本成立。

假设 3：机械核对部分的判定是确定性的。依据是检查器对同一输入的输出逐字节可复现，回归套件 78 条断言全部通过。

假设 4：单份输出代表该臂在该场景的行为。这是资源约束下的简化，样本量影响见第六节。

假设 5：结论限于同一模型家族与受控素材。跨模型差异可能达到一个数量级（阶段 0 实测破折号频率 DeepSeek 5.16 对 GPT 0.11，每千字），不作外推。

假设 6：任务约束（字数、形态）属于任务的一部分，违反即失败。依据是执行轮中长度越界与形态错位都被判分端记为失败点。

3.2 符号说明

表 1 列出正文反复使用的符号，其余符号在首次出现处就地说明。

表 1 符号说明

符号	说明	单位
R、B	规则版输出、基线版输出	—
s	判分端给出的加权分	分

符号	说明	单位
ε	判分口味误差	分
σ	判分误差尺度	分
Δ	规则版与基线版的分差	分
G	四道硬门的判定向量	—
Ω+、Ω−	通过子空间、取消资格子空间	—
C_1、C_2	误删素材断言的成本、漏删空话的成本	—
p	候选句为空话的后验概率	—
k	结论所在句的序号	句
n	每臂每场景的输出份数	份

四、模型的建立与求解

4.1 测量模型：判分噪声与通过线

判分端给出的分数是真实质量与口味误差之和：

$$s = s^{*} + \varepsilon, \quad (1)$$

其中 s^{*} 为真实分，ε 为误差。双向重复对同一文本给出两个独立观测，其差值提供误差尺度的估计。pilot-2 的六对判定中，分数落在正负 5 分内的为 4 对，平均漂移 4.25 分，取 $\hat{\sigma} \approx 4.2$ 分。

单场景单次判定下，分差的检出阈约为两倍误差尺度：

$$|\Delta| > 2\hat{\sigma} \approx 8.4 \text{ 分}。 \quad (2)$$

图 3 给出 pilot-2 六对判定的漂移绝对值与两条参考线。两对超过 8 分检出阈，两对在 4 分附近，两对低于 2 分。这说明单次判定只能分辨中等以上的效应。

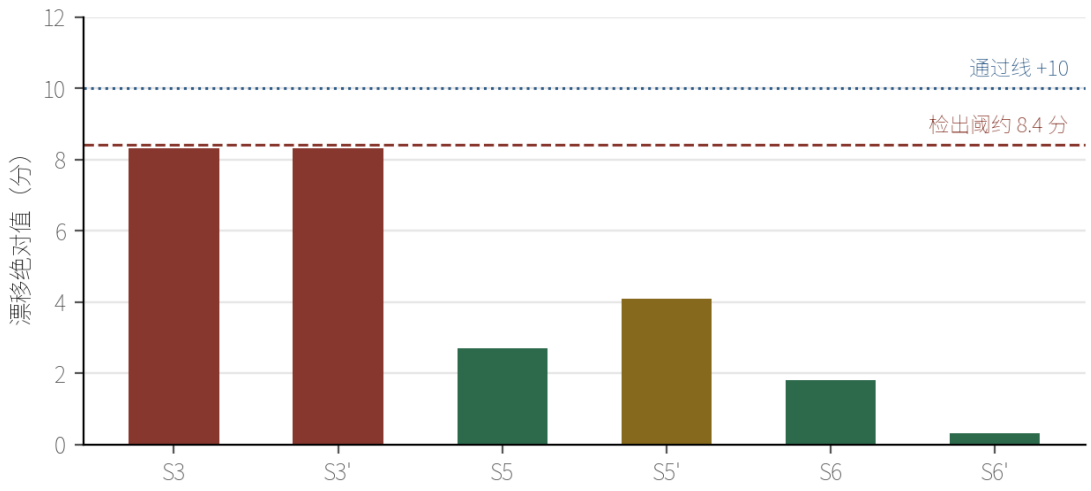


图 3 pilot-2 六对判定的漂移绝对值与检出阈、通过线

由式 (2) 得到通过线的取值依据：取不低于基线加 10，既高于检出阈，又为档位取整留出余量。这一取值不是经验拍定，而是测量精度的直接推论。同理，双向一致率低于 90% 时应先修判分表：仪器不准时测不出物体变化。

分差还受益于配对设计。同一判分端判定两臂时，误差中的共同成分相消：

Var(Δ) = Var(s_R) + Var(s_B) − 2Cov(s_R, s_B)。　（3）

当协方差为正时，分差的方差小于两份方差之和，这是结论优先表述为相对量的原因。

4.2 硬门模型：不对称成本下的二值筛选

每道硬门对应一类失效，门的严格程度由失效成本决定。保真失效使读者按错误信息行动，误杀使读者丢失作者说过的话，两类成本都足以否定整份输出；格式与空转类失效只影响读感。据此把输出空间切为通过子空间 Ω+ 与取消资格子空间 Ω−，加权分只在 Ω+ 上有定义：

E[s | G = 1]，　（4）

分差只在两臂都通过时有定义：

Δ = E[s_R | G_R = 1] − E[s_B | G_B = 1]。　（5）

一方取消资格时式 (5) 无定义，应记无定义而不是给低分。pilot-2 中出现过失败却给出 77.1 分的自相矛盾输出，正是估计量无定义时的错误填补，此后立规：硬门失败不参与排序与分差。

4.3 删除规则模型：R12 作为分类器

改写场景中每个候选句面临删或留的决策，两类错误成本不同。按贝叶斯决策，当且仅当

$p \cdot C_2 > (1 - p) \cdot C_1$　（6）

时删除该句。判定条件是空话的后验概率与成本比的比较。本文的规则把候选句映射到四族特征：可指认对象、条件标记、归属式论断、空壳谓语。归属式论断满足 p≈0，在任何成本比下都不删。

三臂消融给出该模型的实证。A 臂无约束，B 臂三条显式禁令，C 臂完整规则集，在文档段落场景上的结果如图 4。B 臂把「新增素材没有的内容」压到零，与 C 臂持平，但在「删掉素材已有的断言」上与 A 臂同为 2 处，C 臂为 0。在只需抑制添加的讲稿场景上，三臂在两项指标上均为零或持平。

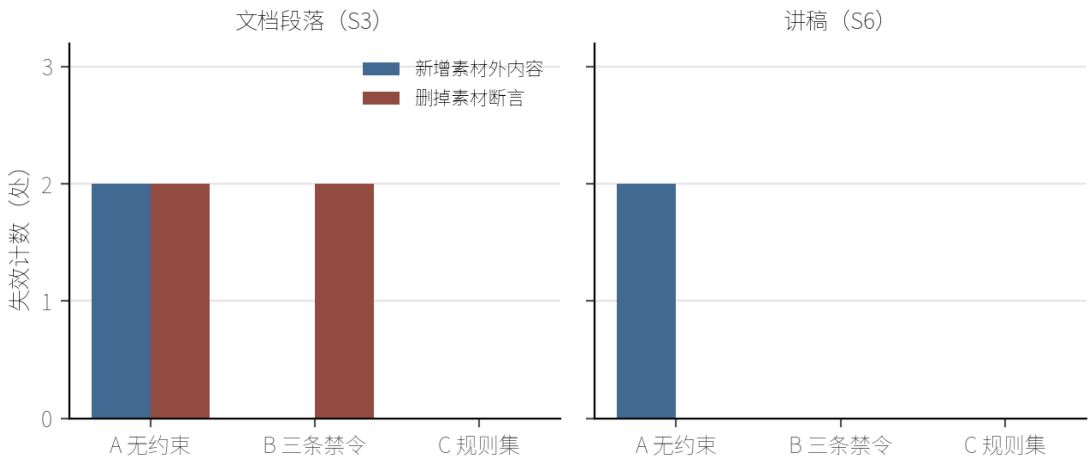


图 4 三臂消融在文档段落与讲稿场景上的失效计数

读数是：禁令移动决策阈，规则层提供区分特征。用分类器的语言，禁令把工作点推向多删一侧，规则层改变的是整条曲线。由此得到反例纪律的必要性：反例是估计 p 的负样本，没有反例，规则的假阳性率不可知。

4.4 缺口决策模型：期望损失与发问阈值

素材缺口分两级。设第 i 个缺口的读者误填期望损失为 L_i，一次交互成本为 c。发问的条件是

Σ_{i∈A} L_i > c，　(7)

其中 A 为影响照做的缺口集合。多个缺口合并进一次发问可降低单位交互成本，因此问句条数按合并后的实际条数计。非交互环境中 c 视为无穷大，发问降级为缺口声明。

4.5 结论前置的读取成本模型

设结论位于第 k 句，读者读到结论即停，则期望读取成本为

E[L] = k。　(8)

结论前置把 k 从段落长度压到常数，标题写成摘要把只读标题的读者成本压到标题数。这解释了两点设计：组织层权重高于格式层，因为前者省时间、后者省精力；场景权重随用途变化，复现类文档中结论前置的边际收益下降。

五、实证检验

5.1 试点轮次

四轮试点的读数汇总于表 2。pilot-1 给出规则版的首次正向分差；pilot-2 给出判分一致率与漂移；pilot-3 检验未决陷阱；pilot-4 用三臂消融检验规则层的增量。

表 2 四轮试点与一轮执行轮的关键读数

轮次	场景	关键读数	用途
pilot-1	S1、S4	规则版 94.7 与 91.1，基线 78.9 与 64.3	首次正向分差
pilot-2	S3、S5、S6	硬门一致率 6/6，分数一致率 4/6，漂移 4.25 分	估误差尺度
pilot-3	S4b	两臂均守住未决陷阱	否证未决假设
pilot-4	S3、S6	规则 0/0，禁令 0/2，基线 2/2	分离规则层增量
ur1	U1 至 U6	规则 3/6，基线 1/6	六场景执行

pilot-3 的结果否证了设计假设的一半：未决被补成结论的失效，在明确给出不得补充的指令后并未复现，说明这一类问题靠一句红线即可压制，不需要风格规则。

5.2 执行轮

执行轮（ur1）于 2026 年 10 月 17 日完成，协议同第二节：生成臂与改写臂各 6 个，互不可见；12 个判分端实例，含 6 个首判与 6 个复判；匿名化种子 777。单用例通过条件为硬门全过、六层检查点全过、

粒度达标。

六个场景的结果见表 3。规则臂通过 3 个场景，基线臂通过 1 个，两个场景双败。规则臂的胜场全部落在保真维度：不丢安装路径、不补术语通识定义、不补编造例子与外部机制。基线臂的五个失败场中四个是编造。双败场暴露规则臂的短板：改写场景漏删一句空话，格式场景标题连读不足。

表 3 执行轮六场景判定结果

场景	规则臂	基线臂	规则臂失败点	基线臂失败点
U1 配置讲解	通过	失败	—	丢安装路径，加站外建议
U2 项目 README	通过	失败	—	补 Maven 作用域通识定义
U3 概念讲解	通过	失败	—	补编造例子与外部机制
U4 草稿改写	失败	失败	漏删一句空话	三句空话全留并加因果
U5 格式文档	失败	失败	两个空标题	编造命令行
U6 英文发布说明	通过	通过	—	—

图 5 以矩阵形式给出同一结果。行是场景，列是臂，色块为判定。规则臂的失败集中在右列（删除侧与组织层），基线臂的失败集中在保真侧。

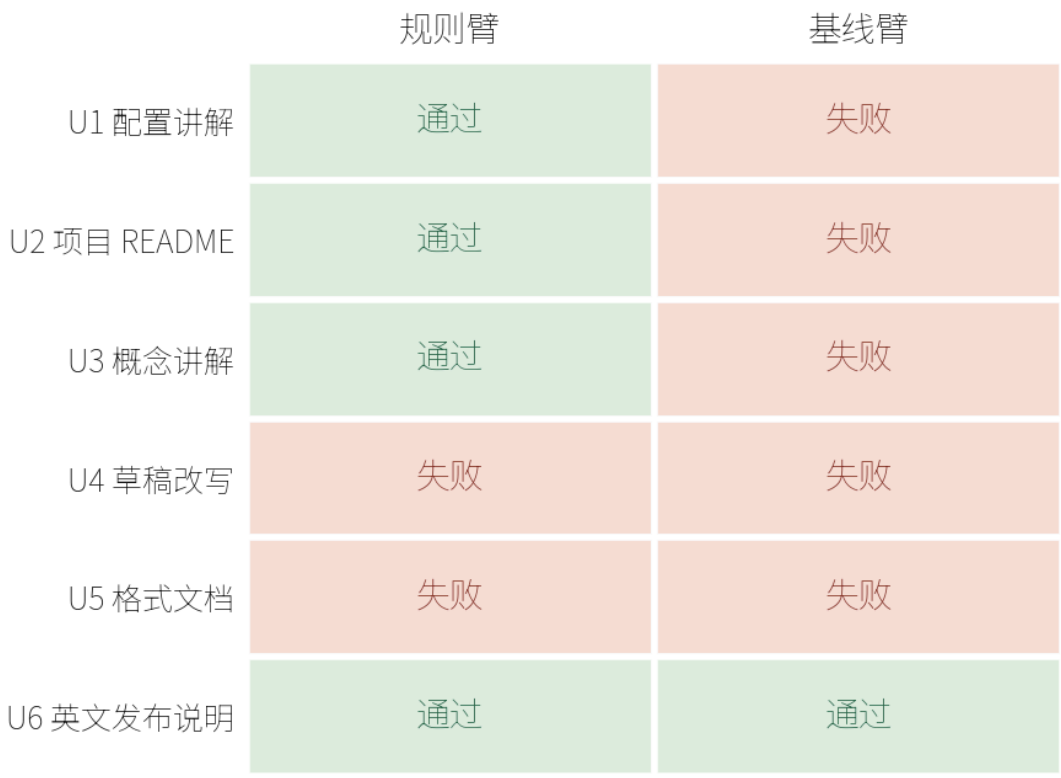


图 5 执行轮六场景的判定矩阵

5.3 装置修订与复测

执行轮的机械核对暴露一类器材缺陷。事实表令牌是连续字符串，输出的行内代码反引号、表格单元格与短语插入会隔断字符串，内容在场却报缺。12 份输出中 6 份报缺，逐条分类后真实丢失 1 处、假阳性

5 处，假阳性率 5/6。

修订分两步：检查器比对增加 markdown 语法剥离面，事实表令牌改为原子粒度；同时把粒度纳入通过条件，BA 判分包修复标签对调。用修订后的器材重跑第二轮（ur2），12 份输出只有 1 份报 G1a 缺项，且是真实丢失，5 处假阳性全部清零。图 6 对比修订前后的缺项构成。

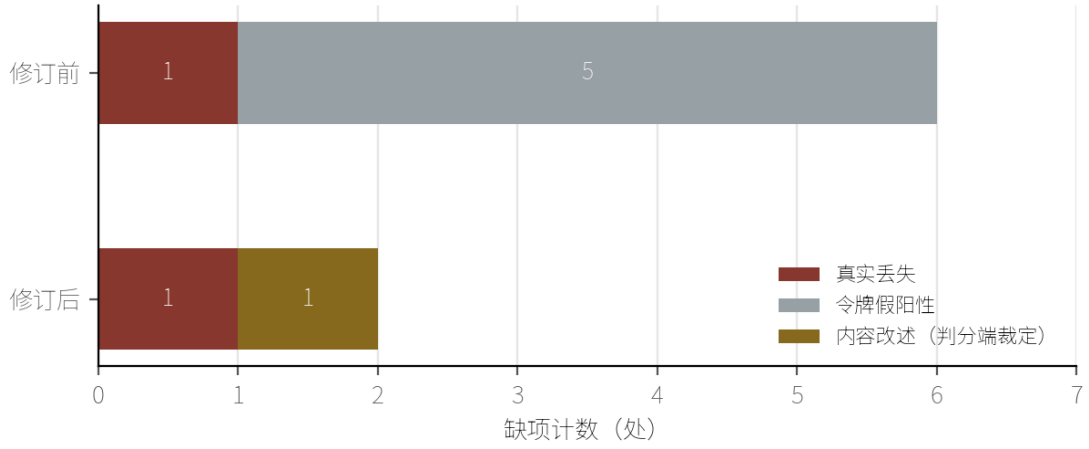


图 6 器材修订前后的缺项构成对比

第二轮的双序判定给出三条读数。第一，规则臂的三个首轮通过场（U1 配置讲解、U2 项目 README、U3 概念讲解）在第二轮因长度越界失败：U1 超上限 61 字，U2 低于下限 160 字，U3 低于下限 252 字，压缩与膨胀两个方向都出现，而内容侧无失分。第二，U4 草稿改写的判定跨轮分歧：同一句「为后续工作提供了可复制的范式」在首轮被判为空话，在第二轮被双序判分判为素材断言，两轮的两名判分端独立地各执一端，说明该句处在判据的边界上，需要场景卡点名。第三，U6 英文场景中基线臂造出素材没有的「the team」施事，规则臂的缺口句点名来源文档，规则层在「命名主体」这一条上占优。表 4 汇总两轮结果。

表 4 两轮执行轮的判定汇总

场景	首轮规则臂	首轮基线臂	次轮规则臂	次轮基线臂
U1 配置讲解	通过	失败	失败	失败
U2 项目 README	通过	失败	失败	失败
U3 概念讲解	通过	失败	失败	失败
U4 草稿改写	失败	失败	通过	失败
U5 格式文档	失败	失败	通过	失败
U6 英文发布说明	通过	通过	通过	失败

两轮的共同信号：基线臂的失败始终在保真侧（丢路径、补通识定义、编造例子与施事），规则臂的失败始终在任务约束侧（长度、标题、删除不完全）。规则层解决的是「不加不丢」，任务约束的遵守需要另一组规则，这是下一轮修订的靶点。

5.4 控制变量测试：长度规则

为检验长度规则 S10 的边际效果，设计一组小范围控制变量测试。同场景、同素材、同任务指令，唯一差别是所读规则版本：v2 无 S10，v3 有 S10。选两个场景：U7 邮件通知（当时 200–260 字，5.5 后校准为 180–240）与 U3 概念讲解（500–900 字，素材自然长度约 250 字）。结果见表 5。

表 5 控制变量测试结果

组	去空白字数	区间	判定	失败点
U7 无 S10	236	达标	失败	两处复述；缺口完全未声明
U7 有 S10	222	达标	失败	一处复述
U3 无 S10	248	未达标	失败	粒度低 252 字；内容与六层全过
U3 有 S10	520	达标	失败	补出两处素材外机制；三处复述

读数是两条。素材撑得住下限的场景，S10 没有长度收益（U7 两臂都达标），差别只在缺口声明。素材撑不住下限的场景，S10 的净效应为负：U3 从粒度失败变成保真失败，前者伤任务遵守，后者伤内容可信。两组的共同机制是补白：模型把「达到下限」执行成「把字数填满」，填法是复述与补机制。

据此修订 S10，把素材置于下限之前，分三步执行：先查是否漏了素材事实，再在素材内部展开，仍不足则按实际长度交付并在说明里注明；同时列出三类禁止的补白，任一出现则长度达标也记失败。不加 S10 时规则臂在两轮执行轮的三个场景越界，加了初版 S10 又会诱导补白，两组实测合起来才得到正确写法：长度是硬约束，素材是更硬的约束。

5.5 全量矩阵与第二臂复测

S10 修订后，2026-10-17 的 ctl4–ctl10 轮次把八个场景跑成两到三条臂，共 19 条，判分按各场景卡面检查点，不用统一六层模板。结果见表 6。

表 6 全量矩阵

场景	臂数	通过	失败点
U1 环境配置讲解	3	2	第二臂仍按旧材料写“三个 channel 各执行一次”，与单 channel 任务冲突
U2 README	2	2	无
U3 概念讲解	3	2	第二臂 410 字，低于 500
U4 草稿改写	3	1	第二臂 G3 同族空话回填；第三臂必留归属断言语序改写被判缺失
U5 集群上手	2	2	无
U6 英文发布说明	2	2	无
U7 变更邮件	2	2	无
U8 决策备忘	2	1	第二臂“人月”首现未解释，L4 失败

读数是三条。第一，U2、U5、U6、U7 两臂都过，说明 S10 在素材撑得住的场景没有诱导补白，也没有丢事实。第二，U1、U3 三臂两过，失败分别是模型没有服从任务更新与长度波动，不是 S10 失效。第

三，U4 与 U8 的失败落在 G3 同族空话、必留断言语序与 L4 术语首现；这三处把靶点从 S10 移到卡设计与判分输入。

这与 5.4 的控制变量结论一致：S10 解决的是“素材优先、禁止补白”，不解决任务指令是否写全硬条件、区间是否高于素材容量、判分单是否附素材全文。ctl9 与 ctl10 的修卡复测支持后三条：U1 上限 500→700、U7 下限 200→180、U6 任务补“首句给结论”后，三条代表臂都通过。

5.6 一致性与敏感性

复判实例与首判的一致情况：6 个复判中 3 个与首判一致，2 个不一致，1 个因错挂句子而不成立。不一致的两例按协议人工终判，终判依据都能指到场景卡与机械计数。这说明硬门与带片段定位的检查点可以稳定，对 borderline 语义项，判分端口味差仍存在，所以判分表要求否必须附片段。

长度敏感性：规则臂在两个长文场景压缩到下限之下（296 字对 500 字，470 字对 600 字），说明减法规则在长度受约束时过度执行，与三臂消融中禁令臂的过度删除同向。修订后长度纳入通过条件，由判分端逐例核对。

六、结论

本文围绕「如何让语言清晰性约束可执行、可验收」建立了一套方法与装置，并用四轮试点、两轮执行轮与一组控制变量测试检验。主要结论如下。

第一，规则层的价值在区分能力，不在抑制强度。三臂消融显示，三条显式禁令与完整规则集在「抑制新增」上等效，在「保留素材断言」上禁令误删 2 处、规则集零误删。规则层提供的是一组可判定的特征，禁令只移动决策阈。这一结论决定了两条设计纪律：每条规则必须同时写一条反例，反例是估计规则假阳性率的负样本。

第二，通过线应当由测量精度推出，不应凭经验拍定。判分误差尺度约 4.2 分，单次判定的检出阈约为 8.4 分，通过线取不低于基线加 10。绝对分受判分端平移影响，结论以相对量表述。

第三，机械门的确定性以事实表令牌的原子性为条件。首轮执行轮中 12 份输出有 6 份报事实缺项，逐条分类后只有 1 份是真实丢失，其余 5 份是行内代码反引号、表格单元格与短语插入隔断连续字符串造成的假阳性。令牌原子化与语法剥离两处修订后，假阳性清零而真实丢失仍被捕获。

第四，规则层与任务长度约束是两件事。两轮执行轮中规则臂的保真侧零失分，长度侧在三个场景越界，方向有超有欠。把长度写进规则层（S10）是对这一结论的直接回应，控制变量测试见 5.4，全量矩阵见 5.5。

局限有四处。样本量小，每场景两到三条臂，误差条来自判分噪声而不是输出抽样，估计的是条件效应不是任务分布上的平均效应。判分端与生成端同模型家族，自我偏好无法完全隔离，结论限于相对比较。素材卡是受控刺激，外推到自然写作需要额外假设。语义判据仍有或然性，双向重复把它压到可复现但没有压到零；U4 第三臂的必留断言语序判定就是一处边界，严格字面与语义在场各能自洽，本轮按严格字面记失败。

后续工作按证据强度排序。扩大素材与场景的重复采样，把单点效应变成区间估计；跨模型家族复测，为阈值补适用范围标注；继续把语义判据中可机械化的部分下探，本轮已验证令牌原子性与语法剥离两项。

参考文献

[1] Controllable Text Generation for LLMs: A Survey. arXiv:2408.12599.

[2] Evaluating the Evaluators: Are readability metrics reliable for LLM text? arXiv:2508.19221.

[3] AI Slop measurement. arXiv:2509.19163.

[4] 判分偏置相关文献. arXiv:2406.11817, arXiv:2310.10076, arXiv:2407.01085, arXiv:2509.03647.

[5] lieflat-less-ai-tone. 629 篇、282.7 万字人机对照语料的频率测量与规则收录门槛. 开源仓库 larashero3-dotcom/lieflat-less-ai-tone.

[6] speak-human-tw. 38 条模式、42 条成对用例与量化阈值. 开源仓库 Raymondhou0917/speak-human-tw.

[7] blader/humanizer. 25 条模式的强度分层. 开源仓库 blader/humanizer.

[8] plain-language-skill. 中英分轨的白话改写规则. 开源仓库 olivervvvv/plain-language-skill.

[9] ASD-STE100 简化技术英语规则目录（Issue 9）. 开源仓库 AminBlg/SimpleEnglish.